

Segmentación de tumores cerebrales

Jeferson Alexander del Rio Herrera

Departamento de Ingeniería de Sistemas, Universidad de Antioquia
Medellín, Colombia

Resumen—Este trabajo se centrará en la segmentación de tumores cerebrales por medio del uso de arquitecturas de deep learning como U-Net y Attention U-Net combinado con las funciones de costo Cross-Entropy, Dice Loss, Focal Tversky Loss, and Dice + Cross-Entropy. Con lo anterior se tiene como propósito analizar como la arquitectura y la función de costo afecta la segmentación de la imagen de un tumor.

Palabras Clave—Tumor cerebral, función de costo, segmentación de imagen, arquitecturas de deep learning, desbalance de clases

I. DESCRIPCIÓN DEL PROBLEMA

Los sistemas de salud a nivel mundial enfrentan una presión creciente por mejorar la rapidez y eficiencia en el diagnóstico médico. Uno de los desafíos más complejos en este contexto es la detección y análisis de tumores cerebrales, ya que requieren una identificación precisa para apoyar la planificación del tratamiento y mejorar los resultados clínicos de los pacientes.

La resonancia magnética es la herramienta estándar utilizada por los especialistas para visualizar las estructuras cerebrales e identificar anomalías. Sin embargo, el análisis manual de estas imágenes y la delimitación de las regiones tumorales es un proceso lento, ya que depende de la experiencia de un radiólogo. Además, este proceso es susceptible a factores humanos como el cansancio o la carga laboral, lo que puede afectar la consistencia de la segmentación. Según [2], también existe variabilidad entre especialistas, evidenciada en coeficientes Dice que oscilan entre el 74 % y el 85 %, lo que refleja diferencias significativas en la interpretación de las imágenes.

Esta variabilidad y dependencia del análisis manual generan limitaciones importantes en términos de tiempo, escalabilidad y reproducibilidad de los diagnósticos. En entornos clínicos con alta demanda, estas limitaciones pueden traducirse en retrasos en el diagnóstico y, en consecuencia, en el inicio del tratamiento.

En este contexto, surge la necesidad de desarrollar soluciones automatizadas, robustas y confiables que apoyen a los profesionales de la salud en la segmentación de imágenes médicas. El uso de técnicas de deep learning ha demostrado un alto potencial para abordar este problema, permitiendo no solo acelerar el proceso de análisis, sino también mejorar la precisión y reducir la variabilidad entre observadores. Sin embargo, aún existen desafíos relacionados con la elección de

arquitecturas adecuadas y funciones de pérdida que permitan capturar correctamente las características complejas de los tumores, especialmente en regiones con bajo contraste o bordes difusos.

II. OBJETIVO

Evaluar el impacto de diferentes funciones de pérdida en el rendimiento de modelos de deep learning para la segmentación de tumores cerebrales, con el fin de predecir con mayor precisión las máscaras de segmentación a partir de imágenes de resonancia magnética y analizar cómo estas funciones influyen en la calidad de las regiones tumorales identificadas.

III. DATASET

En este trabajo, el problema se aborda utilizando el conjunto de datos BraTS 2021, obtenido de la plataforma Kaggle.

El conjunto de datos consta de resonancias magnéticas multimodales, incluyendo secuencias T1, T1ce, T2 y FLAIR, junto con máscaras de segmentación anotadas por expertos. Estas máscaras identifican las regiones tumorales incluyendo múltiples subregiones como el tumor con realce, el núcleo tumoral y el edema.




Figura 1. Secuencias de resonancia magnética

III-A. Tipo de datos

El conjunto de datos contiene imágenes médicas volumétricas 3D, donde cada caso de paciente incluye cuatro modalidades de resonancia magnética: T1 para visualizar la estructura anatómica, T1ce que resalta las regiones tumorales activas, T2 para visualizar líquido y edema, FLAIR para enfatizar el edema y las lesiones.

Cada modalidad se almacena como un volumen 3D, en formato NIfTI (.nii.gz).

Además, cada caso incluye una máscara de segmentación, donde cada voxel(píxel 3D) está etiquetado según las regiones tumorales.

Clase	Color	Descripción
0	Negro	Corresponde al fondo o tejido cerebral normal
1	Rojo	Indica el núcleo tumoral necrótico o no realzado, es decir, la parte interna del tumor que no capta contraste.
3	Verde	Corresponde al edema, una región inflamada que rodea al tumor y suele ser más extensa.
4	Azul	Representa el tumor activo o realzado, que capta contraste en la resonancia magnética y es especialmente relevante para el diagnóstico

Cuadro I

CLASES DE LA MÁSCARA DE SEGMENTACIÓN




Figura 2. Clases de la máscara de segmentación

III-B. Tamaño de datos

Número de muestras: El conjunto de datos BraTS 2021 contiene 1251 casos de pacientes donde cada caso incluye 4 volúmenes de resonancia magnética y 1 máscara de segmentación.

Tamaño de almacenamiento: Tamaño total del conjunto de datos es aproximadamente 12.48 GB. Cada caso de paciente tiene un tamaño entre 50 y 100 MB.

III-C. Dimensiones de las modalidades de resonancia

Cada una de las modalidades de resonancia magnética T1, T1ce, T2 y FLAIR presenta dimensiones uniformes de $240 \times 240 \times 155$ vóxeles al igual que la segmentación tiene las mismas dimensiones. Estas modalidades están previamente registradas y alineadas espacialmente.

IV. MÉTRICAS DE DESEMPEÑO

IV-A. Métricas de Machine Learning

El rendimiento de los modelos implementados para la segmentación de tumores cerebrales se evaluará mediante métricas estándar en el análisis de imágenes médicas, tales como el coeficiente de Dice, la precisión, el recall y IoU.

El coeficiente de Dice se emplea como métrica principal, debido a su capacidad para medir el grado de solapamiento entre la segmentación predicha y la segmentación real ya que es robusta frente al desequilibrio de clases que es común en imágenes médicas donde las regiones tumorales suelen

ocupar una porción reducida del volumen total.

El recall ya que evalúa la capacidad del modelo para identificar correctamente las regiones tumorales, minimizando los falsos negativos y la precisión para medir la proporción de predicciones positivas correctas.

Por ultimo se medirá la intersection over Union (IoU) para evaluar la calidad de la segmentación al medir el grado de solapamiento entre la predicción del modelo y la máscara real.

IV-B. Métricas de Negocio

IV-C. Métricas de negocio

Además de las métricas de Machine Learning, también se evaluará el rendimiento del modelo a través de indicadores relacionados con su impacto en el entorno clínico y operativo.

Una de las métricas más relevantes es la reducción del tiempo de diagnóstico, ya que la automatización del proceso de segmentación puede disminuir significativamente el tiempo requerido por un especialista para analizar las imágenes médicas.

Asimismo, la capacidad del modelo para detectar correctamente las regiones tumorales tiene un impacto directo en la reducción de errores diagnósticos, especialmente en la disminución de falsos negativos, los cuales representan un riesgo crítico en aplicaciones clínicas.

Otro aspecto importante es la reducción de la variabilidad entre especialistas, dado que los modelos de deep learning pueden generar segmentaciones más consistentes, contribuyendo a una mayor estandarización en los diagnósticos.

V. RESULTADOS PREVIOS

Se revisaron trabajos que abordan la segmentación de tumores cerebrales mediante técnicas de deep learning, enfocándose en problemas similares con los mismos datos.

The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS) aborda el desafío clínico de la segmentación automatizada de gliomas en imágenes de resonancia magnética multicontraste, una tarea dificultada por la alta variabilidad en la forma, extensión y localización de los tumores. Se usaron modelos como Random Forests, Máquinas de Soporte Vectorial y regularización espacial mediante Campos Aleatorios de Markov. Los resultados revelaron que, aunque los mejores algoritmos alcanzan niveles de precisión similares a la variabilidad entre expertos con dice scores de 80 % para el tumor completo, 70 % para el núcleo y 60 % para la región activa.

Brain Tumor Segmentation with Deep Neural Networks utilizando Redes Neuronales Profundas para superar desafíos como la variabilidad extrema en la forma y localización de los tumores, así como el desequilibrio de clases en las imágenes. Se usó una arquitectura de dos vías (Two-pathway) y una

arquitectura en cascada (InputCascadeCNN). Se Alcanzó un Dice de 0.88, con una precisión de 0.87 y recall de 0.89. Además de su precisión, destaca la eficiencia computacional, logrando segmentar un cerebro completo en un tiempo de entre 25 segundos y 3 minutos, lo que lo hace entre 30 y 45 veces más rápido que los métodos líderes de la época.

A novel focal tversky loss function with improved attention u-net for lesion segmentation, aborda el desafío del desbalance de clases en la segmentación de imágenes médicas, donde las lesiones como las mamarias y de piel ocupan una fracción mínima del área total, lo que suele causar inestabilidad en el entrenamiento, se uso una arquitectura Attention U-Net mejorada que integra una pirámide de imágenes multiescala. La innovación central es la Focal Tversky Loss que generaliza el índice de Tversky y utiliza un exponente focal para centrar el aprendizaje en ejemplos difíciles. En cuanto a los resultados, el modelo alcanzó un Dice score de 0.804, precisión de 0.829 y un recall de 0.817 en el dataset BUS 2017 y Dice de 0.856, precisión de 0.858 y un recall de 0.897 en el dataset ISIC 2018.

Brain Tumor Segmentation Using Deep Learning on MRI Images emplea un modelo de Red Neuronal Convolutiva Profunda cuya arquitectura principal se basa en U-Net con la función de pérdida cross entropy y el optimizador Adam. El modelo fue evaluado utilizando el conjunto de datos BraTS con 335 imágenes anotadas, logrando resultados sobresalientes que superaron a otros modelos como YOLOv2. Accuracy 99.21 %, dice coefficient 0.9012, mean IoU 0.9123, precisión 0.9923, recall 0.9678 y AUC Cercana a 0.9.

Automated Segmentation of Brain Tumor MRI Images Using Deep Learning propone un sistema completamente automatizado para la segmentación de gliomas que combina la extracción de características de textura mediante Gray Level Co-occurrence Matrix y la búsqueda eficiente con Vantage Point Trees para alimentar un ensamble de dos redes: una U-Net y una CNN tridimensional. Este enfoque híbrido permite superar la subjetividad y lentitud del análisis manual, logrando en el conjunto de validación una Accuracy de 99.40 %, dice score de 99.40 % una precisión de 99.41 %, un F-Score de 99.4 % y un recall de 99.39 % para el tumor completo.

REFERENCIAS

- [1] Menze, B. H., Jakab, A., Bauer, S., Kalpathy-Cramer, J., Farahani, K. et al. (2014), 'The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS)', in *IEEE Transactions on Medical Imaging*, 34(10), 1993-2024.
- [2] Havaei, M., Davy, A., Warde-Farley, D., Biard, A., Courville, A., Bengio, Y., ... & Larochelle, H. (2017), 'Brain tumor segmentation with deep neural networks', in *Medical image analysis*, 35, 18-31
- [3] Abraham, N., & Khan, N. M. (2019), 'A novel focal tversky loss function with improved attention u-net for lesion segmentation', in *2019 IEEE 16th international symposium on biomedical imaging (ISBI 2019)* (pp. 683-687)
- [4] Mostafa, A. M., Zakariah, M., & Aldakheel, E. A. (2023), 'Brain tumor segmentation using deep learning on MRI images.', in *Diagnostics*, 13(9), 1562.
- [5] Rajendran, S., Rajagopal, S. K., Thanarajan, T., Shankar, K., Kumar, S., Alsubaie, N. M., ... & Mostafa, S. M. (2023), 'Automated segmentation of brain tumor MRI images using deep learning.', in *IEEE Access*, 11, 64758-64768.