

Segmentación de tumores cerebrales

Jeferson Alexander del Rio Herrera
Departamento de Ingeniería de Sistemas, Universidad de Antioquia
Medellín, Colombia

Resumen—Este trabajo se centrará en la segmentación de tumores cerebrales por medio del uso de arquitecturas de deep learning como U-Net y Attention U-Net combinado con las funciones de costo Cross-Entropy, Dice Loss, and Dice + Cross-Entropy. Con lo anterior se tiene como propósito analizar como la arquitectura y la función de costo afecta la segmentación de la imagen de un tumor.

I. DESCRIPCIÓN DE LA SOLUCIÓN PROPUESTA

La solución desarrollada tiene como objetivo la segmentación automática de tumores cerebrales a partir de imágenes de resonancia magnética utilizando técnicas de aprendizaje profundo. Para ello, se emplea el conjunto de datos BraTS 2021, que proporciona imágenes multimodales y máscaras de segmentación generadas. La solución propuesta comprende varias etapas: preprocesamiento de los datos, generación eficiente de lotes para entrenamiento, entrenamiento de modelos de segmentación y evaluación de desempeño.

II. DESCRIPCIÓN DE LA ESTRUCTURA DE LOS NOTEBOOKS ENTREGADOS

Con el fin de facilitar la organización, reproducibilidad y análisis de los experimentos, el proyecto fue dividido en varios notebooks, cada uno encargado de una etapa específica del proceso de desarrollo y evaluación de los modelos de segmentación de tumores cerebrales.

Notebook 01 - Exploración de datos

Este notebook se utiliza para realizar el análisis exploratorio del conjunto de datos BraTS 2021. En esta etapa se inspeccionan las imágenes de resonancia magnética y las máscaras de segmentación, se analizan las dimensiones de los volúmenes, las etiquetas presentes en las máscaras y la distribución de clases. Además, se generan visualizaciones que permiten comprender mejor las características de los datos antes de iniciar el preprocesamiento.

Notebook 02 - Preprocesado.ipynb

Este notebook implementa todo el proceso de preparación de los datos para el entrenamiento de los modelos. Entre las tareas realizadas se encuentran:

- Extracción del dataset original.

- Carga de los volúmenes de resonancia magnética.
- Normalización de intensidades.
- Selección de cortes relevantes.
- Eliminación de cortes sin tumor.
- Redimensionamiento de imágenes y máscaras.
- Construcción de imágenes multicanal utilizando las modalidades FLAIR, T1, T1ce y T2.
- Almacenamiento de los datos procesados en formato `.npy`.
- Compresión y almacenamiento del conjunto de datos procesado para su reutilización.
- Por ultimo guardado de los datos en google drive.

Notebook 03 - Arquitectura de línea base

Este notebook contiene la implementación de la arquitectura U-Net utilizando la función de coste crossentropy. También incluye el proceso de validación cruzada empleado para evaluar distintas configuraciones de hiperparámetros, particularmente el número de filtros iniciales de la red.

Notebook 04 - U-Net con Dice Loss

Implementa el entrenamiento de la arquitectura U-Net utilizando Dice Loss como función de pérdida principal. Este experimento permite analizar el comportamiento de una función de pérdida basada en solapamiento frente al problema de segmentación de tumores cerebrales.

Notebook 05 - U-Net con Dice Loss + Cross-Entropy

En este notebook se entrena la arquitectura U-Net utilizando una función de pérdida híbrida compuesta por Dice Loss y Cross-Entropy. El objetivo es combinar la estabilidad del aprendizaje proporcionada por Cross-Entropy con la capacidad de Dice Loss para manejar el desbalance de clases.

Notebook 06 - Attention U-Net.ipynb

Contiene la implementación y entrenamiento de la arquitectura Attention U-Net utilizando la configuración base definida para el proyecto. Este notebook permite evaluar el impacto de los mecanismos de atención sobre el desempeño de la segmentación.

Notebook 07 - Attention U-Net con Dice Loss

Este experimento combina la arquitectura Attention U-Net con Dice Loss. Su objetivo es determinar si la incorporación simultánea de mecanismos de atención y una función de pérdida orientada al solapamiento mejora la calidad de la segmentación.

Notebook 08 - Attention U-Net con Dice Loss + Cross-Entropy

Corresponde al experimento final del proyecto. En este notebook se entrena la arquitectura Attention U-Net utilizando la función de pérdida híbrida Dice Loss + Cross-Entropy.

III. OBTENCIÓN Y PREPARACIÓN DE LOS DATOS

Los datos utilizados para el entrenamiento de la red neuronal corresponden a imágenes de resonancia magnética cerebral obtenidas del conjunto de datos público BraTS 2021, disponible en Kaggle. La descarga del dataset se realizó mediante la librería kagglehub.

El dataset se encuentra comprimido en un archivo .tar, por lo que el primer paso consistió en descomprimir su contenido para acceder a las carpetas individuales de cada paciente. Cada paciente contiene cuatro modalidades de resonancia magnética: FLAIR, T1, T1ce y T2, además de su respectiva máscara de segmentación.

Después de la extracción, se realizó un proceso de preprocesamiento para adaptar los datos al entrenamiento de los modelos U-Net y Attention U-Net. Para ello, se crearon dos carpetas principales: una carpeta para almacenar las imágenes procesadas y otra para almacenar las máscaras correspondientes.

Posteriormente, las imágenes de las cuatro modalidades fueron normalizadas en un rango de 0 a 255 y convertidas a formato uint8. Luego, se seleccionaron únicamente los cortes entre las posiciones 30 y 120 del volumen, ya que en esta región se concentra con mayor frecuencia la información relevante del cerebro. Además, solo se conservaron aquellos cortes cuya máscara contenía información tumoral.

Para cada corte seleccionado, se extrajeron las cuatro modalidades de resonancia y se redimensionaron a un tamaño de 128×128 píxeles. Después, estas modalidades se combinaron en una sola imagen de cuatro canales, donde cada canal representa una modalidad distinta: FLAIR, T1, T1ce y T2. La máscara correspondiente también fue redimensionada a 128×128 píxeles, utilizando interpolación de vecino más cercano para conservar correctamente las clases originales de segmentación.

Finalmente, tanto las imágenes como las máscaras fueron guardadas en formato .npy. Cada archivo generado representa un corte 2D de un paciente, listo para ser utilizado en el proceso de entrenamiento y evaluación de los modelos.

Una vez completado el preprocesamiento, la carpeta con las imágenes y máscaras procesadas fue comprimida en un archivo .zip. Este archivo se sube a Google Drive, para posteriormente ser usado en los otros notebooks.

IMPORTANTE: Es necesario ejecutar previamente el Notebook 02 para dejar disponible el conjunto de datos procesado requerido para el entrenamiento y evaluación de los modelos.

IV. DIVISIÓN DE LOS DATOS

Una vez completado el preprocesamiento, las muestras generadas fueron divididas en conjuntos de entrenamiento, validación y prueba. En total se utilizaron 800 resonancias de pacientes para el entrenamiento y test, siendo un total de 47067 mil imágenes y 47067 mil máscaras. Para entrenamiento se utilizaron 640, para validación 80 y para test 80 pacientes respectivamente para cada modalidad.

La división se realizó de forma aleatoria manteniendo la correspondencia entre imágenes y máscaras, teniendo la precaución de que las imágenes de un paciente solo estén presentes ya sea solo en entrenamiento, validación o test. De esta manera, se garantiza que las métricas obtenidas reflejen el desempeño real de los modelos en escenarios nuevos.

V. GENERACIÓN EFICIENTE DE DATOS

Ya que el conjunto de datos procesado contiene muchas imágenes y cargar todas las muestras simultáneamente en memoria RAM generaría un consumo excesivo de recursos o incluso podría bloquear esta, especialmente durante el entrenamiento del modelo.

Para solucionar este problema se implementó un generador personalizado denominado BrainTumorGenerator, basado en la clase Sequence de TensorFlow/Keras. Este generador carga dinámicamente los datos desde disco únicamente cuando son requeridos por el proceso de entrenamiento.

Entre las funciones realizadas por el generador se encuentran:

- Carga de imágenes y máscaras desde archivos .npy.
- Normalización de las imágenes al rango $[0,1]$.
- Conversión de las máscaras a formato multiclase.
- Remapeo de la etiqueta 4 a 3 para obtener clases consecutivas.
- Construcción automática de lotes de entrenamiento.

- Mezcla aleatoria de muestras al finalizar cada época.

VI. ARQUITECTURAS DE SEGMENTACIÓN

Con el objetivo de analizar el impacto de la arquitectura de red neuronal y de diferentes funciones de pérdida sobre el desempeño de la segmentación de tumores cerebrales, se seleccionaron dos arquitecturas ampliamente utilizadas en el ámbito de la segmentación médica: U-Net y Attention U-Net. Asimismo, se evaluaron distintas funciones de pérdida, incluyendo Cross-Entropy, Dice Loss y la combinación Dice + Cross-Entropy.

Ambas arquitecturas reciben como entrada imágenes multicanal de tamaño $128 * 128$ píxeles, donde cada canal corresponde a una modalidad diferente de resonancia magnética.

La salida de los modelos corresponde a una segmentación multiclase con cuatro categorías:

- Clase 0: Fondo o tejido sano.
- Clase 1: Núcleo tumoral necrótico o no realizado.
- Clase 2: Edema.
- Clase 3: Tumor activo o realizado.

Además, ambas arquitecturas fueron implementadas utilizando una estructura de cuatro niveles de codificación y cuatro niveles de decodificación, permitiendo extraer características jerárquicas a diferentes escalas espaciales.

VI-A. U-Net

U-Net es una arquitectura encoder-decoder diseñada específicamente para tareas de segmentación biomédica. Durante la fase de codificación, la red aprende representaciones progresivamente más abstractas de la imagen mediante bloques convolucionales y operaciones de MaxPooling. Posteriormente, durante la fase de decodificación, la resolución espacial es recuperada mediante operaciones de upsampling y conexiones de salto.

La elección de U-Net se fundamenta en varios aspectos. En primer lugar, constituye una de las arquitecturas más utilizadas en segmentación médica y ha demostrado resultados competitivos en múltiples ediciones del desafío BraTS. En segundo lugar, las conexiones de salto permiten preservar información espacial de alta resolución, aspecto fundamental para delimitar correctamente los bordes de las regiones tumorales. Finalmente, su estructura relativamente simple permite utilizarla como modelo base para comparar el efecto de las diferentes funciones de pérdida evaluadas en este trabajo.

VI-B. Attention U-Net

Attention U-Net es una extensión de la arquitectura U-Net que incorpora mecanismos de atención en las conexiones entre encoder y decoder. Estos módulos permiten que la red aprenda automáticamente qué regiones de la imagen contienen información relevante para la tarea de segmentación.

La principal motivación para utilizar Attention U-Net radica en la naturaleza del problema abordado. En las imágenes de resonancia magnética cerebral, las regiones tumorales suelen ocupar una pequeña proporción de la imagen total y presentan formas irregulares y alta variabilidad entre pacientes. Los mecanismos de atención ayudan a la red a concentrarse en estas regiones relevantes mientras reducen la influencia de áreas anatómicas que no aportan información significativa para la segmentación.

Arquitectura	Función de pérdida	Métricas de evaluación
U-Net	Cross-Entropy	Dice Score, Intersection over Union (IoU)
U-Net	Dice Loss	Dice Score, Intersection over Union (IoU)
U-Net	Dice + Cross-Entropy	Dice Score, Intersection over Union (IoU)
Attention U-Net	Cross-Entropy	Dice Score, Intersection over Union (IoU)
Attention U-Net	Dice Loss	Dice Score, Intersection over Union (IoU)
Attention U-Net	Dice + Cross-Entropy	Dice Score, Intersection over Union (IoU)

Cuadro I
COMBINACIÓN DE ARQUITECTURA CON FUNCIONES DE COSTE

VII. LIMITACIONES COMPUTACIONALES

La búsqueda de hiperparámetros estuvo condicionada por las limitaciones de recursos computacionales disponibles durante el desarrollo del proyecto. Los experimentos fueron ejecutados utilizando las GPU gratuitas proporcionadas por Google Colab.

Sin embargo, este servicio impone restricciones de uso que limitan el tiempo continuo de acceso a la GPU. Después de periodos prolongados de entrenamiento, Google Colab puede suspender temporalmente el acceso a la aceleración por GPU durante aproximadamente 24 horas. Esta situación puede interrumpir procesos largos de validación cruzada y retrasar significativamente la ejecución de experimentos.

Debido a estas restricciones, la exploración de hiperparámetros se limitó a configuraciones consideradas relevantes para el problema, específicamente la evaluación de 16 y 32 filtros iniciales.

Adicionalmente, las limitaciones de tiempo de ejecución y disponibilidad de GPU obligaron a restringir el proceso

de validación cruzada a únicamente dos particiones (*folds*) y un máximo de cinco iteraciones por configuración evaluada. Aunque esta estrategia permitió obtener una estimación razonable del desempeño de los modelos, una validación cruzada con un mayor número de *folds* e iteraciones habría proporcionado resultados estadísticamente más robustos.

En particular, aumentar el número de particiones y el número de configuraciones evaluadas habría permitido explorar de forma más exhaustiva el espacio de hiperparámetros y determinar con mayor precisión el número óptimo de filtros iniciales para cada arquitectura. Esto podría conducir a mejoras adicionales en las métricas de segmentación obtenidas, especialmente considerando que U-Net y Attention U-Net pueden responder de manera diferente a cambios en la capacidad de representación de la red.

VIII. ENTRENAMIENTO DEL MODELO

Una vez finalizado el proceso de validación cruzada y seleccionada la configuración de hiperparámetros con mejor desempeño, se procedió al entrenamiento final de cada modelo utilizando la totalidad de los datos disponibles para entrenamiento. Esta estrategia permite que el modelo aproveche la mayor cantidad posible de información durante la fase de aprendizaje, favoreciendo la generación de representaciones más robustas de las diferentes regiones tumorales.

Se utilizaron mecanismos de control como *Early Stopping*, *Model Checkpoint* y reducción adaptativa de la tasa de aprendizaje para evitar el sobreajuste y conservar el mejor modelo obtenido durante el entrenamiento.

Una vez completado el entrenamiento final, el modelo seleccionado fue evaluado utilizando el conjunto de datos de test, compuesto por imágenes que no participaron ni en el entrenamiento ni en la validación cruzada. Esta evaluación permite estimar la capacidad de generalización del modelo sobre datos no vistos previamente y proporciona una medida objetiva de su desempeño real.

IX. RESULTADOS

En esta sección se presentan los resultados obtenidos durante el proceso de entrenamiento, validación y prueba de las diferentes configuraciones evaluadas. Para cada combinación de arquitectura y función de pérdida se reportan las principales métricas de desempeño. Adicionalmente, se incluye el tiempo total de entrenamiento requerido por cada configuración, con el fin de analizar no solo la precisión alcanzada, sino también el costo computacional asociado a cada experimento.

IX-A. U-Net con función de pérdida Cross-Entropy

Métricas	Train	Validación	Test
Dice Score	0.8726	0.8061	0.7963
IoU	0.8273	0.6839	0.6827
Perdida	0.0090	0.0199	0.0190
Tiempo	49m	—	—

Cuadro II

RESULTADOS DEL MODELO U-NET CON CROSS-ENTROPY

IX-B. U-Net con función de pérdida Dice

Métricas	Train	Validación	Test
Dice Score	0.8576	0.8265	0.8133
IoU	0.7434	0.6713	0.6615
Perdida	0.1424	0.1736	0.1868
Tiempo	25 m	—	—

Cuadro III

RESULTADOS DEL MODELO U-NET DICE

IX-C. U-Net con función de pérdida Dice más Cross-Entropy

Métricas	Train	Validación	Test
Dice Score	0.9019	0.8345	0.8245
IoU	0.8217	0.6996	0.6870
Perdida	0.1144	0.1961	0.2067
Tiempo	52m	—	—

Cuadro IV

RESULTADOS DEL MODELO U-NET CON DICE MÁS CROSS-ENTROPY

IX-D. Attention U-Net con función de pérdida Cross-Entropy

Métricas	Train	Validación	Test
Dice Score	0.8747	0.8011	0.7872
IoU	0.8300	0.6783	0.6671
Perdida	0.0088	0.0213	0.0206
Tiempo	30m	—	—

Cuadro V

RESULTADOS DEL MODELO ATTENTION U-NET CON CROSS-ENTROPY

IX-E. Attention U-Net con función de pérdida Dice

Métricas	Train	Validación	Test
Dice Score	0.8222	0.8019	0.7683
IoU	0.5440	0.5666	0.5315
Perdida	0.1778	0.1982	0.2319
Tiempo	35m	—	—

Cuadro VI

RESULTADOS DEL MODELO ATTENTION U-NET CON DICE

IX-F. Attention U-Net con función de pérdida Dice más Cross-Entropy

Métricas	Train	Validación	Test
Dice Score	0.9139	0.8337	0.8225
IoU	0.8411	0.6904	0.6839
Perdida	0.1002	0.1978	0.2102
Tiempo	41m	—	—

Cuadro VII

RESULTADOS DEL MODELO ATTENTION U-NET DICE MÁS CROSS-ENTROPY




Figura 1. U-Net con Dice más Cross-Entropy




Figura 2. Attention U-Net con Dice más Cross-Entropy

X. ANÁLISIS RESULTADOS

Los resultados obtenidos permiten evaluar el efecto de la arquitectura de segmentación y de la función de pérdida sobre la capacidad de los modelos para identificar las diferentes regiones tumorales presentes en las imágenes de resonancia magnética.

X-A. Influencia de la función de pérdida

Los resultados muestran que la función de pérdida utilizada tiene un impacto significativo sobre el desempeño final de los modelos. En ambas arquitecturas se observa que las configuraciones basadas exclusivamente en Cross-Entropy obtienen resultados competitivos, alcanzando valores de Dice Score cercanos a 0.80 en el conjunto de prueba. Sin embargo, la incorporación de Dice Loss produce una mejora en la capacidad de segmentación al optimizar directamente el solapamiento entre las regiones segmentadas y las máscaras reales.

La combinación Dice + Cross-Entropy obtuvo los mejores resultados en ambas arquitecturas. En el caso de U-Net se alcanzó un Dice Score de 0.8245 y un IoU de 0.6870 en el conjunto de prueba, mientras que Attention U-Net obtuvo un Dice Score de 0.8225 y un IoU de 0.6839. Estos resultados sugieren que la combinación de una función basada en clasificación píxel a píxel con una función basada en solapamiento permite aprovechar las ventajas de ambos enfoques.

Un aspecto relevante es que Dice Loss por sí sola no produjo los mejores resultados en todas las configuraciones. Particularmente, en Attention U-Net se observa una disminución importante del IoU hasta 0.5315, indicando dificultades para optimizar simultáneamente los mecanismos de atención y la función de pérdida basada únicamente en solapamiento.

X-B. Comparación entre arquitecturas

La comparación entre U-Net y Attention U-Net muestra que ambas arquitecturas alcanzan niveles de desempeño similares. Aunque los mecanismos de atención fueron diseñados para mejorar la capacidad de la red para localizar regiones relevantes dentro de la imagen, las mejoras obtenidas respecto a U-Net convencional fueron mínimas.

La mejor configuración de U-Net superó ligeramente a la mejor configuración de Attention U-Net tanto en Dice Score como en IoU sobre el conjunto de prueba. La diferencia observada es inferior al 1

X-C. Capacidad de generalización

En todos los experimentos se observa una disminución del desempeño al pasar del conjunto de entrenamiento al conjunto de validación y posteriormente al conjunto de prueba. Este comportamiento es esperado y refleja la presencia de cierto grado de sobreajuste inherente al entrenamiento de modelos profundos.

Sin embargo, las diferencias observadas son relativamente moderadas. Por ejemplo, en la configuración U-Net con Dice + Cross-Entropy el Dice Score disminuye de 0.9019 en entrenamiento a 0.8345 en validación y 0.8245 en prueba. Esta reducción indica que el modelo conserva una buena capacidad para generalizar a imágenes no vistas durante el entrenamiento.

Asimismo, la proximidad entre las métricas de validación y prueba sugiere que la partición de los datos fue adecuada y que los resultados obtenidos son representativos del comportamiento esperado del modelo en nuevos pacientes.

X-D. Eficiencia computacional

Los tiempos de entrenamiento muestran diferencias importantes entre las configuraciones evaluadas. Las funciones de pérdida híbridas presentan los mayores tiempos de entrenamiento debido a la necesidad de calcular simultáneamente múltiples términos durante la optimización. No obstante, este incremento computacional se ve compensado por la mejora obtenida en las métricas de segmentación.

Desde una perspectiva de costo-beneficio, U-Net con Dice + Cross-Entropy representa la configuración más equilibrada, ya que proporciona el mejor desempeño global sin requerir la complejidad adicional de los mecanismos de atención.

XI. CONCLUSIONES

Los resultados obtenidos indican que la selección de la función de pérdida tiene una influencia más significativa sobre el desempeño final que la elección entre U-Net y Attention U-Net. En particular, las funciones híbridas

demonstraron ser más efectivas para abordar el desbalance de clases característico de la segmentación de tumores cerebrales.

Además, los experimentos evidencian que arquitecturas relativamente simples como U-Net continúan siendo altamente competitivas cuando se combinan con estrategias de optimización adecuadas. Esto coincide con tendencias recientes observadas en la literatura científica, donde gran parte de las mejoras en segmentación médica provienen de modificaciones en las funciones de pérdida y los procedimientos de entrenamiento más que de incrementos sustanciales en la complejidad arquitectónica.

Entre las principales limitaciones del trabajo se encuentran las restricciones computacionales asociadas al uso de Google Colab, las cuales limitaron la cantidad de hiperparámetros explorados y el número de particiones utilizadas durante la validación cruzada. Una exploración más amplia podría permitir identificar configuraciones aún más eficientes para cada arquitectura.